Audit di fairness – Modello di previsione del reddito

Nov 8, 2026 · @Tommaso Perilli

1. Sintesi

Verdetto: Non approvato

Il modello prevede se una persona ha un reddito superiore a 50.000 dollari l'anno, in uno scenario di proposta di prestiti: un uso ad alto rischio secondo l'AI Act. L'accuratezza è dell'85,5%, ma il recall complessivo (59,8%) è appena sotto la soglia di 0,60: il modello scarta circa 4 persone su 10 con reddito alto.

Il problema più grave è la fairness. A parità di reddito alto, il modello riconosce le donne meno spesso degli uomini (recall 54,2% contro 60,9%) e le persone Black meno spesso di quelle White (53,7% contro 60,3%), pur non conoscendo sesso ed etnia. Nessun criterio di fairness è superato.

Il rilascio non è approvato finché non saranno completate le azioni ad alta priorità della sezione 7 e un nuovo audit con gli stessi criteri.

2. Sistema e contesto d'uso

Voce	Descrizione
Cosa fa il sistema	Prevede se una persona guadagna più di 50.000 dollari l'anno
Uso ipotizzato	Una banca che usa il modello per decidere a quali clienti proporre un prestito
Chi subisce la decisione	Le persone che chiedono un prestito o che sono potenziali clienti della banca
Classificazione AI Act	Alto rischio: valutazione dell'affidabilità creditizia delle persone
Tipo di modello	Regressione logistica (un modello semplice e diffuso)

Un errore del modello ha conseguenze concrete sulle persone. Chi ha un reddito alto ma viene scartato per errore non riceve la proposta di prestito. Se questo accade più spesso a un gruppo, per esempio alle donne, l'errore diventa una discriminazione sistematica. Per

questo l'AI Act classifica la valutazione del credito come uso ad alto rischio, e chiede di verificare la fairness prima del rilascio.

3. Dati (AI Act, art. 10)

Fonte: dataset pubblico Adult Income, censimento USA del 1994. Persone totali: 48.842, di cui il 23,9% con reddito alto (oltre 50.000 dollari l'anno).

Controllo di coerenza: i totali per sesso e per gruppo etnico danno entrambi 48.842.

Sesso	Persone	Quota sul totale	Persone nel test (stima, 30%)	Quota con reddito alto
Uomini	32.650	66,8%	circa 9.800	30,4%
Donne	16.192	33,2%	circa 4.860	10,9%

Gruppo etnico	Persone	Quota sul totale	Persone nel test (stima, 30%)	Quota con reddito alto
White	41.762	85,5%	circa 12.530	25,4%
Black	4.685	9,6%	circa 1.410	12,1%
Asian-Pac-Islander	1.519	3,1%	circa 460	26,9%
Amer-Indian-Eskimo	470	1,0%	circa 140	11,7%
Other	406	0,8%	circa 120	12,3%

Osservazioni

- **Gruppi poco rappresentati:** Asian-Pac-Islander (3,1%), Amer-Indian-Eskimo (1,0%) e Other (0,8%). Nel test avranno circa 460, 140 e 120 persone: le misure su Amer-Indian-Eskimo e Other saranno poco affidabili. Sono sottorappresentate anche le donne: 33% del dataset, contro circa metà della popolazione.
- **Differenze già presenti nei dati:** la quota con reddito alto è del 30,4% tra gli uomini e del 10,9% tra le donne (2,8 volte). Per gruppo etnico è del 25,4% (White) e del 26,9% (Asian-Pac-Islander), contro il 12,1% (Black), l'11,7% (Amer-Indian-Eskimo) e il 12,3% (Other): circa il doppio.
- **Fatto e rischio:** queste differenze sono nei dati, non ancora nel modello. Il rischio è che il modello le impari e le amplifichi; i Passi 5 e 6 lo verificano.

- **Riferimento per la sezione 5:** con il 23,9% di redditi alti, un modello che rispondesse sempre "no" avrebbe un'accuratezza di circa il 76%.
- **Possibili "indizi nascosti":** anche senza Sex e Race, la colonna relationship rivela il sesso, perché contiene i valori Husband e Wife. Altre colonne possono riflettere sesso o etnia: marital-status, occupation e hours-per-week per il sesso, native-country per l'etnia.
- **Qualità dei dati:** workclass, occupation e native-country contengono valori mancanti; le informazioni sono autodichiarate nel censimento.
- **Età e contesto dei dati:** i dati sono del 1994 e solo statunitensi. 50.000 dollari di allora valgono oggi più del doppio, il mercato del lavoro è cambiato e le categorie etniche sono quelle del censimento USA. Per una banca europea non rappresenterebbero il contesto d'uso, come invece chiede l'art. 10 dell'AI Act.

4. Metodo di test e criteri di accettazione (AI Act, artt. 9 e 15)

Come è stato testato

- Divisione dei dati: 70% addestramento, 30% test, mai visti dal modello durante l'addestramento.
- Sesso ed etnia **esclusi** dalle informazioni date al modello, ma usati per misurare i risultati per gruppo.
- Misure usate: accuratezza, precision, recall, selection rate.
- Gruppi analizzati: sesso e gruppo etnico.

Criteri di accettazione

Compila questa tabella **prima** di guardare i risultati per gruppo (Passi 5 e 6). Scegli tu le soglie e scrivi perché.

Criterio	Soglia scelta	Perché questa soglia
Accuratezza complessiva minima	almeno 0,80	Deve superare chiaramente il 76% del modello "pigro" che risponde sempre "no" (vedi sezione 3). Altrimenti il modello non aggiunge valore.

Criterio	Soglia scelta	Perché questa soglia
Recall complessivo minimo	almeno 0,60	Il modello deve riconoscere almeno 6 persone con reddito alto su 10. Sotto questa soglia escluderebbe dalle proposte di prestito troppe persone che ne avrebbero diritto.
Differenza massima di recall tra gruppi	non oltre 0,05	È il criterio più importante: a parità di reddito reale, ogni gruppo deve essere riconosciuto con probabilità simile. Una differenza maggiore significa trattare peggio un gruppo a parità di condizioni.
Rapporto minimo di selection rate tra gruppi	almeno 0,80	È la "regola dei quattro quinti". Va usata come campanello d'allarme, non come verdetto: nei dati la quota di redditi alti è già diversa tra i gruppi (sezione 3), quindi una parte della differenza è attesa. Va letta insieme al recall.
Numero minimo di persone per considerare affidabile un gruppo	almeno 100 persone nel test, di cui almeno 30 con reddito alto	Il recall si calcola solo sulle persone con reddito alto. Amer-Indian-Eskimo e Other ne avranno circa 15 ciascuno nel test (140 × 11,7% e 120 × 12,3%): troppo pochi per una misura stabile.

Regola di decisione

- Tutti i criteri superati: rilascio approvato.
- Superati i criteri complessivi, ma non uno dei criteri tra gruppi: approvato solo con condizioni (azioni correttive e monitoraggio, sezione 7).
- Non superato un criterio complessivo: rilascio non approvato.
- Un gruppo sotto la soglia di affidabilità è segnato come **non valutabile**, non come superato. Va dichiarato tra i limiti (sezione 6).

5. Risultati

5.1 Risultato complessivo (Passo 4)

Misura	Valore	Cosa significa, in parole semplici
Accuratezza	85.5%	Su 100 persone del test, il modello ne classifica correttamente circa 86. È sopra il 76% del modello "pigro" che risponde sempre "no": il modello aggiunge valore.
Precision	74.6%	Quando il modello dice "reddito alto", ha ragione 3 volte su 4. Una proposta di prestito su 4 andrebbe a chi in realtà ha un reddito basso.
Recall	59.8%	Su 100 persone con reddito alto, il modello ne riconosce circa 60. Le altre 40 non riceverebbero la proposta di prestito.
Falsi negativi	1408	Persone con reddito alto che il modello scarta: non riceverebbero la proposta pur avendone diritto. È l'errore che danneggia la persona.
Falsi positivi	715	Persone con reddito basso che il modello considera con reddito alto: riceverebbero una proposta che rischiano di non poter sostenere. È l'errore che costa soprattutto alla banca.

L'accuratezza dell'85,5% va letta con cautela: solo il 23,9% delle persone ha reddito alto, quindi un modello che rispondesse sempre 'no' otterrebbe già circa il 76%. Il guadagno reale è di circa 10 punti. Il limite vero emerge dal recall: 59,8%, appena sotto la soglia di 0,60 fissata nella sezione 4. Il modello scarta circa 4 persone su 10 con reddito alto (1.408 nel test).

5.2 Risultati per sesso (Passo 5)

Sesso	Persone nel test	Accuratezza	Precision	Recall	Selection rate
Uomini	9796	81,8%	74,2%	60,9%	24,7%
Donne	4857	92,9%	76,9%	54,2%	8%
Differenza massima	–	11,1%	2,7%	6,6%	16,7% (rapporto 0,32)

Il recall delle donne è 54,2% contro il 60,9% degli uomini: a parità di reddito alto, il modello riconosce 54 donne su 100 e 61 uomini su 100. La differenza (6,6 punti) supera la soglia di 5. Il selection rate è 8% contro 24,7%, con un rapporto di 0,32 contro lo 0,80 richiesto; nei dati il rapporto era 0,36, quindi il modello amplifica la differenza. L'accuratezza più alta delle donne (92,9%) non è un vantaggio: con l'89% di redditi bassi, basta dire quasi sempre 'no'. La precision è simile (76,9% contro 74,2%). Entrambi i gruppi sono abbastanza numerosi da rendere le misure affidabili. Togliere la colonna Sex non è bastato: il modello tratta peggio le donne a parità di reddito, e la differenza supera i criteri fissati.

5.3 Risultati per gruppo etnico (Passo 6)

Gruppo etnico	Persone nel test	Accuratezza	Precision	Recall	Selection rate
White	12455	84,9%	75,1%	60,3%	20,3%
Black	1471	91,2%	70,1%	53,7%	9,8%
Asian-Pac-Islander	461	82,0%	69,3%	62,2%	24,7%
Amer-Indian-Eskimo (non valutabile)	138	90,6%	83,3%	47,6%	8,7%
Other (non valutabile)	128	89,8%	55,6%	35,7%	7%
Differenza massima	–	9,2%	27,8%	26,5%	17,7%
Differenza massima gruppi affidabili	-	9,2%	5,8%	8,5%	14,9% (rapporto 0,40)

Amer-Indian-Eskimo e Other non sono valutabili: nel test hanno solo 21 e 14 persone con reddito alto, sotto la soglia di 30. Su Other, una persona riconosciuta in più sposterebbe il recall di circa 7 punti. Per questo la differenza massima complessiva (26,5 punti di recall) non è una prova solida, e il confronto si basa sui tre gruppi affidabili: White, Black e Asian-Pac-Islander.

Tra questi, il recall va dal 62,2% (Asian-Pac-Islander) e 60,3% (White) al 53,7% (Black): una differenza di 8,5 punti, oltre la soglia di 5. A parità di reddito alto, le persone Black vengono riconosciute meno spesso. Il selection rate è del 9,8% per il gruppo Black contro il 20,3% del gruppo White (rapporto 0,48) e il 24,7% di Asian-Pac-Islander (rapporto 0,40), sotto lo 0,80 richiesto. Rispetto al gruppo White il modello riflette la differenza già presente nei dati (rapporto 0,48 anche lì); rispetto ad Asian-Pac-Islander la amplifica leggermente (0,40 contro 0,45 nei dati).

L'accuratezza più alta del gruppo Black (91,2%) non è un vantaggio: dipende dalla bassa quota di redditi alti, come per le donne. La precision è simile tra i gruppi (tra 69,3% e 75,1%). Anche qui togliere la colonna Race non è bastato: il criterio sulla differenza di recall non è superato.

5.4 Confronto con i criteri

Criterio	Soglia	Risultato	Superato?
Accuratezza complessiva minima	almeno 0,80	85,5%	Sì
Recall complessivo minimo	almeno 0,60	59,8%	**No** (per 0,2 punti)
Differenza massima di recall – sesso	non oltre 5 punti	6,6 punti (uomini 60,9%, donne 54,2%)	**No**
Differenza massima di recall – gruppo etnico (gruppi affidabili)	non oltre 5 punti	8,5 punti (Asian-Pac-Islander 62,2%, Black 53,7%)	**No**
Rapporto minimo di selection rate – sesso	almeno 0,80	0,32 (nei dati 0,36)	**No**
Rapporto minimo di selection rate – gruppo etnico (gruppi affidabili)	almeno 0,80	0,40 (nei dati 0,45)	**No**
Affidabilità dei gruppi	almeno 100 persone nel test, di cui 30 con reddito alto	Valutabili: uomini, donne, White, Black, Asian-Pac-Islander. Non valutabili: Amer-Indian-Eskimo (21 con reddito alto) e Other (14)	Parziale

Esito secondo la regola di decisione (sezione 4): un criterio complessivo non è superato (recall), e nessun criterio tra gruppi è superato. Il rilascio è quindi **non approvato**.

Togliere sesso ed etnia è bastato? No. Anche senza le colonne Sex e Race, il modello riconosce meno spesso le donne (6,6 punti di recall in meno rispetto agli uomini) e le persone Black (6,6 punti in meno rispetto al gruppo White). Per il sesso amplifica perfino la differenza già presente nei dati (rapporto di selection rate 0,32 contro 0,36). L'informazione rientra attraverso altre colonne, come relationship, che contiene i valori Husband e Wife.

6. Limiti dell'analisi

L'analisi mostra differenze di trattamento tra i gruppi, ma ha questi limiti, da tenere presenti nel leggere i risultati.

- **Gruppi con pochi casi.** Amer-Indian-Eskimo (138 persone nel test, 21 con reddito alto) e Other (128 persone, 14 con reddito alto) non sono valutabili: una sola persona in più o in meno sposta il loro recall di diversi punti. Anche Black e Asian-Pac-Islander hanno numeri contenuti (circa 190 e 130 persone con reddito alto), quindi le loro differenze hanno un margine di incertezza di alcuni punti. La differenza tra uomini e donne, misurata su gruppi più grandi, è la più solida.
- **Una sola divisione dei dati.** Il test è stato fatto su un'unica divisione addestramento/test. Con una divisione diversa i numeri potrebbero cambiare leggermente; non abbiamo ripetuto la prova.
- **Dati del 1994, solo USA.** La soglia di 50.000 dollari non è aggiornata all'inflazione, il mercato del lavoro è cambiato e le categorie etniche sono quelle del censimento statunitense. I risultati non sono trasferibili a una banca europea di oggi.
- **L'etichetta è un'approssimazione.** Il dataset misura il reddito, non l'affidabilità creditizia: lo scenario del prestito è ipotetico, e "reddito alto" è solo un indicatore semplificato.
- **Un solo modello, una sola soglia.** È stata testata solo una regressione logistica, con la soglia di decisione predefinita. Un modello diverso, o una soglia diversa, potrebbe dare risultati diversi.
- **Solo sesso ed etnia, analizzati separatamente.** Non sono stati analizzati altri gruppi (età, paese di origine) né le combinazioni, per esempio le donne Black, che potrebbero subire un effetto combinato.
- **L'indizio nascosto è un'ipotesi.** Il ruolo della colonna relationship è plausibile ma non verificato: non abbiamo rimosso la colonna per rimisurare il modello.
- **Valori mancanti non analizzati.** Non abbiamo verificato se i valori mancanti in workclass, occupation e native-country riguardino alcuni gruppi più di altri.

7. Raccomandazioni e verdetto (AI Act, art. 72)

Prima del rilascio

Azione raccomandata	Problema che risolve	Priorità
Raccogliere più dati sui gruppi sottorappresentati (donne, Black, Asian-Pac-Islander, Amer-Indian-Eskimo, Other) e riaddestrare	Recall più basso per donne e persone Black; due gruppi non valutabili	Alta

Azione raccomandata	Problema che risolve	Priorità
Verificare il ruolo di relationship e delle altre colonne-indizio: rimuoverle o trasformarle, poi rimisurare	Il bias resta anche senza Sex e Race	Alta
Provare tecniche di riduzione del bias (per esempio i vincoli di fairness di Fairlearn) e rimisurare con gli stessi criteri	Differenze di recall oltre la soglia di 5 punti	Alta
Usare dati recenti e del contesto d'uso reale (clienti europei di oggi)	Dati del 1994, solo USA (AI Act, art. 10)	Alta, prima di qualsiasi uso reale
Prevedere una revisione umana delle persone scartate vicine alla soglia di decisione	1.408 falsi negativi nel test (AI Act, art. 14)	Media
Ripetere il test su più divisioni dei dati	Una sola divisione addestramento/test	Media
Analizzare le combinazioni di gruppi (per esempio donne Black) e altri gruppi come l'età	Analisi limitata a sesso ed etnia, separati	Media

Dopo il rilascio: cosa monitorare

Cosa misurare	Ogni quanto	Soglia di allarme
Recall complessivo	Ogni mese	Sotto 0,60
Recall per sesso e per gruppo etnico	Ogni mese	Differenza oltre 5 punti
Rapporto di selection rate tra gruppi	Ogni mese	Sotto 0,80, o peggiore del rapporto già presente nei dati
Composizione dei dati in arrivo (quote per gruppo, valori mancanti)	Ogni trimestre	Scostamento rilevante rispetto ai dati di addestramento (drift)
Ritest completo con i criteri della sezione 4	A ogni riaddestramento	Qualsiasi criterio non superato blocca il rilascio

Verdetto finale

Non approvato. Il recall complessivo (59,8%) è sotto la soglia di 0,60, e nessun criterio di fairness è superato: a parità di reddito alto, il modello riconosce meno spesso le donne (6,6 punti in meno rispetto agli uomini) e le persone Black (6,6 punti in meno rispetto al gruppo White). Il modello potrà essere rivalutato dopo le azioni ad alta priorità, con un nuovo audit sugli stessi criteri.